

Week 4 Homework

Course: Bioinformatics: From Multi-Omics Data to Discovery

Student: 叶顾霖

Student ID: SUAT24000191

Evidence-aware analysis, verification, and reproducible workflows

Submitted course artifact


Question 1 - Choose the Right Genomic Assay

1. Your reasoning before AI

在接受基础概念讲解后、查看 AI 针对本题的具体方案前，我首先选择 ATAC-seq，比较疾病组与健康对照组中 Gene X 启动子及候选调控区域的染色质可及性，检验 Gene X 上调是否伴随局部开放程度变化。若发现疾病组特异开放区域，我会用 H3K27ac ChIP-seq/CUT&Tag 判断活跃调控状态，再用 Hi-C/Micro-C 检查该区域是否与 Gene X 启动子接触，最后用 CRISPRi 检验其功能。若 ATAC-seq 阴性，我会继续比较 Gene X 启动子的三维接触图谱，而不把阴性结果解释为不存在调控机制。

2. AI-assisted workflow

我向 AI 提供上述方案，并要求：“请批评这个实验设计，指出每项 assay 的直接测量对象、不能证明的内容、遗漏机制、决策分支和必要对照；不要替我作最终决定。” AI 认为主线能够从染色质关联证据逐步走向原生位点扰动，但初始设计过度集中于染色质开放，建议有条件地加入 WGS、WGBS/EM-seq、CAGE/RAMPAGE 和 MPRA。我接受这些补充，但决定依据前一步结果进入相应分支，不对所有样本机械地执行全部实验。



3. Verification

ENCODE 的 ATAC-seq 标准将该实验界定为全基因组染色质可及性分析，并要求生物学重复、文库复杂度、TSS enrichment、FRIP 和重复一致性等质量控制；因此 ATAC peak 只能支持区域开放，不能单独证明调控 Gene X ([ENCODE ATAC-seq](#))。Fulco 等使用 CRISPRi 系统扰动非编码候选区域并检测目标基因表达，说明原生位点扰动可用于建立功能性 enhancer-promoter connection ([Fulco et al., Science, 2016](#))。据此，我保留 ATAC-seq 作为首项筛查，并将 CRISPRi 放在多层候选证据之后；实验需使用多条独立 sgRNA、non-targeting sgRNA，并检查邻近基因表达和细胞活性。

4. Final conclusion

ATAC-seq 测量染色质可及性；H3K27ac ChIP-seq/CUT&Tag 判断活跃调控元件相关状态；WGBS/EM-seq 检测 DNA 甲基化；WGS 寻找编码区和非编码调控变异；CAGE/RAMPAGE 定位转录起始位点和替代启动子；Hi-C/Micro-C 测量空间接触；RNA-seq 比较 Gene X、转录本及邻近基因表达。上述结果只能形成关联模型：开放、H3K27ac 富集和启动子接触共同支持候选增强子，却不能证明因果。MPRA 可检验序列在人工系统中的潜在调控能力，但缺少完整原生染色质环境；CRISPRi 在原生位点抑制候选区域，并以 Gene X 表达变化为 readout，可提供更强因果支持。我的最终策略是先用 ATAC-seq 定位候选区域，再根据结果进入修饰、甲基化、序列、启动子使用和三维接触分支，最后通过带有适当对照的 CRISPRi 验证。

The biological question chooses the assay because each method measures a different regulatory layer, and only their evidence-guided combination can distinguish association from a testable causal mechanism.

Question 2 - From FASTQ to a Trustworthy Analysis Workflow

1. Reasoning before AI

在接受 FASTQ、质量分数和文件格式的基础讲解后、查看 AI 针对本题的完整计划前，我选择以 S01 的双端 WGS 为例设计流程。我的初始思路是先进行 FASTQ 质量检测，再选择与后续资源一致的参考基因组并完成比对；随后处理比对结果、检测和注释变异，最后可视化并解释。经过逐步检查，我将流程明确为：FASTQ QC 与有证据支持的修剪及复检 → 记录准确版本的 GRCh38 → BWA-MEM2 双端比对 → BAM 坐标排序、重复标记、条件性 BQSR 和索引 → SNV/indel 检测与过滤 → VEP 注释 → IGV 核查 → 分开解释技术证据、生物学推断和临床意义。我还检查样本 ID、R1/R2 配对和批次；若疾病状态与批次完全混杂，增加测序深度不能消除偏差。


S01 快照中的四项主要 QC 结果为：约 15% 的 R1 在 cycle 50 后 3' 端中位质量降至 Q12；约 10% reads 形成约 78% GC 的额外肩峰；约 15% read pairs 在 3' 端含 **AGATCGGAAGAGC** 接头；一条模板约占 R1 的 15%。前两项提示末端测序问题和可能污染，接头应按配对方式修剪并重新 QC；重复警告不能用于在 FASTQ 阶段盲目删除相同 reads。

2. AI-assisted workflow

我的原始提示词是：“请你按照作业要求生成对我的流程进行检验并修正的计划。”该提示词表达了先规划的意图，但缺少数据类型和边界。AI 协助完善为：“请先检查并修正我设计的人类双端 WGS 分析流程，只输出各步骤的目的、输入、输出、质量检查点和需要核实的官方文档，暂不执行命令；参考基因组采用 GRCh38，并注意 S01 只有 120 对合成 reads，仅用于格式和质控教学，不能当作真实全基因组数据运行生产流程。”我确认该提示词准确，并接受由其生成的分步计划。

Q2 — Paired-end Human WGS: FASTQ to Interpretable Variants

S01 is a 120-pair synthetic teaching demo: inspect QC only; do not run a production genome pipeline.



Human judgment controls assembly choice, QC thresholds, tool assumptions, evidence strength, and final claims.

3. Verification

AI recommendation	My verification	Final decision
使用配对模式处理快照中已观察到的 3' 接头和末端低质量	FastQC 官方文档说明 adapter content 随 read 末端累积，可用于判断是否需要 trimming；本题快照给出了明确接头	修改后接受：记录软件版本、实际接头和参数，保留原始 FASTQ，并在处理后重跑 QC；不盲信默认值

AI recommendation	My verification	Final decision
在比对前删除所有相同 FASTQ reads	相同序列可能是真实高丰度；GATK/Picard 在 SAM/BAM 中依据位置和配对信息标记 duplicates	拒绝：这是我明确否决的建议；改为比对后标记并报告 duplicate metrics
“使用最新人类参考基因组”	GRC 建议以 GRCh38 名称和 assembly accession 明确标识；不同资源还可能包含不同 patch/contig 集合	修改：固定并记录准确 FASTA、accession/checksum、contig 命名和资源兼容性
无条件执行 BQSR	GATK BaseRecalibrator 需要参考序列和 known-sites；这些资源必须与组装版本兼容	修改：只在资源与流程假设满足时执行，并记录输入和版本
将 FILTER=PASS 或 missense_variant 当作致病结论	HTS/VCF 规范和 VEP 分别定义技术记录与后果注释；二者不构成临床因果证据	拒绝：保留分层证据、IGV 核查和独立验证

官方资料核查结果支持最终计划：GRC 将参考组装明确称为 GRCh38，并建议使用唯一 accession；BWA-MEM2 官方示例接受 `ref.fa read1.fq read2.fq` 并输出 SAM；GA4GH/hts-specs 分别规定 SAM/BAM/BAI 与 VCF；GATK 预处理文档将坐标排序、重复标记和 BQSR 作为生成 analysis-ready BAM 的步骤，且 BaseRecalibrator 需要 known-sites；HaplotypeCaller 的队列流程先生成单样本 gVCF，再联合分型并过滤；VEP 官方建议工具与 cache 版本对应，并明确组装；IGV 要求 BAM/CRAM 配套索引。

核查来源：[GRC/NCBI GRCh38](#)、[FastQC Adapter Content](#)、[BWA-MEM2](#)、[HTS specifications](#)、[GATK data preprocessing](#)、[GATK HaplotypeCaller](#)、[Ensembl VEP cache](#)、[IGV alignment files](#)。

4. Final conclusion

最终流程先审核样本表和批次设计，再用 FastQC/MultiQC 诊断原始 FASTQ；只对有明显证据的接头和低质量末端实施配对修剪，并重新质控。真实 WGS 应使用来源、版本和 checksum 明确的 GRCh38，以 BWA-MEM2 比对并保留 read group，随后进行坐标排序、重复标记、条件性 BQSR 和索引。真实队列可使用 HaplotypeCaller 生成单样本 gVCF，再联合分型、过滤并用版本匹配的 VEP 注释；重要候选需在 IGV 中检查深度、链平衡、read-end bias、base quality、MAPQ 和局部重复。S01 仅有 120 对合成 reads，因此本题只用它解释 FASTQ 与 QC 陷阱，不把任何演示性输出冒充全基因组结果。

The analyst, not the AI, is responsible for verifying inputs and reference resources, choosing justified parameters, detecting confounding and artifacts, interpreting evidence limits, and deciding what conclusions require independent validation.

Question 3 - Integrate Multi-Omics Evidence into a Regulatory Hypothesis

1. Your reasoning before AI

在查看 AI 针对本题的分类前，我计划依次检查 RNA-seq、ATAC-seq、H3K27ac ChIP-seq/CUT&Tag、DNA 甲基化和 Hi-C/Micro-C，并认为多层证据只能间接支持候选增强子，仍需 CRISPRi 或 deletion 检验。逐层分析后，我将证据边界明确为：ATAC-seq 反映可及性；H3K27ac 反映活跃启动子或增强子相关状态；低甲基化与活跃状态相容；Hi-C/Micro-C 反映空间接触机会；RNA-seq 反映 Gene Y 表达。它们都不能单独确认调控对象或因果关系。更关键的是，原题只列出可用的数据类型，没有给出任何峰值、甲基化比例、接触频率、表达量、对照或统计结果，因此目前不能判定该区域是不是 Gene Y 的合理候选增强子。

2. AI-assisted workflow

我要求 AI：“把五类组学分别整理为直接观察、生物学解释和缺失证据；不得补造题目未提供的信号；给出至少一种替代解释，并设计能够证伪 Gene Y 增强子模型的原位功能实验。” AI 最初把更强的 ATAC-seq/H3K27ac、较低甲基化、更强接触和 Gene Y 上调写成已观察结果。我拒绝该表述并指出“不要刻意假设”。修正后的工作流是先从真实数据提取每层结果并检查对照、重复、归一化和细胞组成，再建立条件性整合模型；替代解释包括该区域实际调控另一个基因，或信号来自细胞类型比例差异。功能检验选择 CRISPRi，同时测量 Gene Y、邻近基因和细胞状态。



3. Verification

Omics layer	Direct observation available from the prompt	Biological interpretation if supported by real data	Missing evidence
ATAC-seq	未提供候选区域的 peak 或组间差异	较强信号可支持更高染色质可及性	不能确认 enhancer、靶基因或因果
H3K27ac ChIP-seq/CUT&Tag	未提供富集结果	富集可支持活跃启动子/增强子相关状态	不能区分元件类别或确认 Gene Y

Omics layer	Direct observation available from the prompt	Biological interpretation if supported by real data	Missing evidence
DNA methylation	未提供 CpG 甲基化比例	低甲基化可与活跃调控状态相容	可能是转录结果或细胞组成差异
Hi-C/Micro-C	未提供接触矩阵或显著接触	富集接触可支持空间接近	接触不等于调控或因果
RNA-seq	未提供 Gene Y 表达量或比较组	匹配对照中的差异表达可描述转录变化	不能把变化归因于该候选区域

ENCODE 将 ATAC-seq 定义为全基因组染色质可及性测量，并要求重复一致性和信噪比等质量控制，因此不能把一个 peak 直接解释为增强子 ([ENCODE ATAC-seq](#))。H3K27ac 可参与定义活跃 promoter/enhancer 状态，但元件分类依赖多种标记和基因注释 ([ChIP-seq integration review, PMID 29579165](#))。DNA 甲基化虽与转录状态相关，其是否对基因组读取具有指令性仍取决于具体背景 ([Schübeler, Nature 2015, PMID 25592537](#))。4DN 将 Hi-C 的 .hic 文件定义为接触频率矩阵，因此空间接触本身不是功能证明 ([4DN Hi-C format](#))。Fulco 等通过 CRISPRi 扰动非编码元件并检测基因表达来建立功能性 enhancer-promoter connection，支持本题采用原位扰动 ([Fulco et al., Science 2016](#))。

4. Final conclusion

现有题目信息不足以判定该区域是否为 Gene Y 的增强子，因为没有给出任何实际组学结果。分析时应先在匹配样本与对照中分别读取候选区域的 ATAC-seq 可及性、H3K27ac 富集、CpG 甲基化水平、与 Gene Y 启动子的归一化接触频率，以及 Gene Y 的差异表达。只有当真实结果方向一致时，才能把该区域列为合理候选；这些相关证据仍不能排除其调控其他基因或细胞类型比例差异。功能验证采用 dCas9-KRAB CRISPRi，以多条独立 sgRNA 抑制候选区域，设置 non-targeting sgRNA 和 Gene Y 启动子阳性对照，并检测 Gene Y、邻近基因、扰动效率、细胞活力和细胞状态。若 Gene Y 在多条 sgRNA 下可重复下调而邻近基因和细胞状态没有相同异常，可支持该区域对 Gene Y 的因果调控；若只有其他基因变化，则支持替代靶基因模型。作为待检验而非已观察到的结论，假设为：

The candidate element regulates Gene Y by promoting an accessible, active chromatin state and contacting the Gene Y promoter, and this can be tested by CRISPRi of the endogenous candidate region followed by expression analysis of Gene Y and neighboring genes.

Question 4 - AI-Assisted Variant Prioritization

1. Your reasoning before AI

在查看 AI 针对本表的排序结果前，我先定义筛选逻辑。主候选必须满足 **FILTER=PASS**、**DP ≥ 20**、**GQ ≥ 30** 和合成群体频率 **AF ≤ 0.001**。功能后果方面，优先考虑 **splice_acceptor/donor**、**stop_gained** 和 **frameshift**，同时保留质量可靠且罕见的 **missense** 供后续证据排序；不把同义、内含子或基因间变异一概解释为无功能。临床注释方面，优先 **Pathogenic**，将 **Conflicting_interpretations** 和 **Uncertain_significance** 作为次级证据，并降低 **Benign/Likely_benign** 的优先级。由于题目没有表型、遗传模式或家系信息，我不依据基因知名度加分。高影响但未通过技术阈值的变异进入独立复核队列，而不是被解释为不存在。


2. AI-assisted workflow

我的 plan-first 提示词是：“请先根据我预先确定的 **FILTER**、**DP**、**GQ**、**AF**、功能后果和临床注释规则，写出透明的变异筛选与排序计划；先解释每项规则、预计保留和排除的信息、可能的错误线索及需要核验的假设，再生成可复现的 R 代码。不要根据基因知名度加分，也不要合成 ClinVar 标签解释为患者诊断。”随后将计划实现为脚本 **scripts/Q4_variant_prioritization.R**，为每个变异分别记录五项过滤结果、排除原因和证据分数，并输出完整审计表、可靠候选排序和技术复核队列。

Q4 Variant Prioritization

Transparent filters, evidence ranking, false-lead critique, and a functional test

1. Apply the student-defined filters



2. Rank retained candidates using consequence and supplied clinical annotation

Rank	Variant	Gene	Consequence	Clinical label
1	chr17:7673803 G>A	TP53	splice acceptor	Pathogenic
2	chr12:25398284 C>A	KRAS	missense	Conflicting
3	chr13:32316461 C>T	BRCA2	missense	VUS
4	chr19:11200200 C>T	LDLR	missense	Likely benign

Selected candidate

TP53 chr17:7673803 G>A

PASS | DP 80 | GQ 99 | AF 0.00001

splice_acceptor_variant | synthetic Pathogenic label

Priority reflects combined evidence in this table, not patient-specific causality.

Strongest false-lead concern

No phenotype or inheritance model was supplied.
The gene-disease match therefore cannot be evaluated.
The ClinVar ID is illustrative and the splice effect is predicted.

Required experimental test

Confirm DNA call independently -> extract RNA ->
RT-PCR across flanking exons -> sequence cDNA ->
look for exon skipping, intron retention, or cryptic splicing

脚本从 12 个合成变异中保留 4 个可靠候选：TP53 chr17:7673803 G>A、KRAS chr12:25398284 C>A、BRCA2 chr13:32316461 C>T 和 LDLR chr19:11200200 C>T。我最终选择 TP53 变异，因为它通过全部技术阈值，AF=0.00001，后果为 splice_acceptor_variant，并带有合成的 Pathogenic 注释。MSH2 stop_gained 和 MECP2 frameshift 虽然后果严重，但 DP/GQ 不合格，因此只进入技术复核队列。

3. Verification

Check	Authoritative evidence	Decision
剪接受体后果	Ensembl 将 <code>splice_acceptor_variant</code> 定义为改变内含子 3' 端两个碱基区域的变异，并标记为预测 HIGH impact ；同时说明后果严重性排序具有主观性且与转录本有关 (Ensembl calculated consequences)	支持把它列为高优先级预测后果，但不能声称实际剪接已经异常
ClinVar 标签	NCBI 说明 ClinVar 表示变异与疾病、肿瘤类型或药物反应之间的变异级分类，而不是患者个体化解释 (NCBI ClinVar classification)；review status 反映分类证据和共识层级 (ClinVar review status)	Pathogenic 只能参与排序；本题编号是合成示例，不能当作真实临床记录
代码结果	<code>results/Q4_filter_audit.tsv</code> 记录每项过滤结果； <code>results/Q4_ranked_candidates.tsv</code> 给出 4 个候选； <code>results/Q4_technical_validation_queue.tsv</code> 保留技术质量不足的高影响变异	结果可追溯到原始合成表和预先确定的阈值

AI 提出的最强错误线索是：题目没有提供表型和遗传模式，因此无法判断 **TP53** 是否与样本疾病相符。我认为这是最重要的科学限制。其他疑点包括未指定转录本、剪接后果仍是计算预测、ClinVar ID 为教学示例，以及该 DNA 变异尚未独立确认。它们都不否定“继续研究”的优先级，但阻止我把候选排名写成致病结论。

4. Final conclusion

Known evidence：合成表显示 **chr17:7673803 G>A** 位于 **TP53**，满足 **FILTER=PASS**、**DP=80**、**GQ=99** 和 **AF=0.00001**，注释为 **splice_acceptor_variant** 和 **Pathogenic**。Computational inference：这些字段共同使其成为本表中优先级最高的可靠候选；剪接受体后果提示它可能改变前体 mRNA 剪接，但没有证明真实转录本已经异常。Scientific hypothesis：该变异可能破坏 **TP53** 正常剪接受体识别，造成外显子跳跃、内含子滞留或隐蔽剪接位点使用。由于没有表型和遗传模式，不能判断该机制是否解释样本疾病。Required experiment：先用独立 DNA 方法确认变异，再从相关细胞或组织提取 RNA，在相邻外显子设计引物进行 RT-PCR，并对 cDNA 产物测序；与正常对照比较异常条带、剪接连接和正常/异常转录本比例。若样本中无法获得适当 RNA，可用野生型与突变型 minigene 剪接实验作为补充。

Variant chr17:7673803 G>A may influence TP53 by affecting splice-acceptor recognition and TP53 transcript processing; this can be tested by orthogonal DNA confirmation followed by RT-PCR and cDNA sequencing of TP53 transcripts.